

1 Vektorji in matrike

1.1 Vektor je *urejena n-terica števil*, ki jo običajno zapisemo kot stolpec

$$\vec{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

1.2 Produkt *vektorja* \vec{x} s skalarjem α je vektor

$$\alpha \vec{x} = \alpha \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} \alpha x_1 \\ \vdots \\ \alpha x_n \end{bmatrix}$$

1.3 Vsota *vektorjev* \vec{x} in \vec{y} je vektor

$$\vec{x} + \vec{y} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_1 + y_1 \\ \vdots \\ x_n + y_n \end{bmatrix}$$

1.4 Nicelni vektor $\vec{0}$ je tisti vektor, za katerega je $\vec{a} + \vec{0} = \vec{0} + \vec{a} = \vec{a}$ za vsak vektor \vec{a} . Vse komponente nicelnega vektorja so enake 0. Vsakemu vektorju \vec{a} priprada nasprotni vektor $-\vec{a}$, tako da je $\vec{a} + (-\vec{a}) = \vec{0}$. Razlika vektorjev \vec{a} in \vec{b} je vsota $\vec{a} + (-\vec{b})$ in jo navadno zapisemo kot $\vec{a} - \vec{b}$.

Lastnosti vektorske vsote

- $\vec{a} + \vec{b} = \vec{b} + \vec{a}$ (komutativnost)
- $\vec{a} + (\vec{b} + \vec{c}) = (\vec{a} + \vec{b}) + \vec{c}$ (asociativnost)
- $a(\vec{a} + \vec{b}) = a\vec{a} + a\vec{b}$ (distributivnost)

1.5 Linearna kombinacija vektorjev \vec{x} in \vec{y} je vsota

$$a\vec{x} + b\vec{y}$$

1.6 Skalarni produkt vektorjev

$$\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \text{ in } \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \text{ je stevilo}$$

$$\vec{x} \cdot \vec{y} = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

alternativno:

$$\vec{x} \cdot \vec{y} = ||\vec{x}|| ||\vec{y}|| \cos \phi$$

Lastnosti skalarnega produkta

- $\vec{x} \cdot \vec{y} = \vec{y} \cdot \vec{x}$ (komutativnost)
- $\vec{x} \cdot (\vec{y} + \vec{z}) = \vec{x} \cdot \vec{y} + \vec{x} \cdot \vec{z}$ (aditivnost)
- $\vec{x} \cdot (a\vec{y}) = a(\vec{x} \cdot \vec{y}) = (a\vec{x}) \cdot \vec{y}$ (homogenost)
- $\forall \vec{x} \text{ velja } \vec{x} \cdot \vec{x} \geq 0$

1.7 Dolžina vektorja \vec{x} je

$$||\vec{x}|| = \sqrt{\vec{x} \cdot \vec{x}}$$

1.8 Enotski vektor je vektor z dolžino 1.

1.9 Za poljubna vektorja $\vec{u}, \vec{v} \in R^n$ velja:

$$|\vec{u} \cdot \vec{v}| \leq ||\vec{u}|| ||\vec{v}||,$$

enakost velja, v primeru, da sta vektorja vzporedna.

1.10 Za poljubna vektorja $\vec{u}, \vec{v} \in R^n$ velja:

$$||\vec{u} + \vec{v}|| \leq ||\vec{u}|| + ||\vec{v}||.$$

1.11 Vektorja \vec{x} in \vec{y} sta ortogonalna (pravokotna) natakno takrat, kadar je

$$\vec{x} \cdot \vec{y} = 0$$

1.12 Če je ϕ kot med vektorjema \vec{x} in \vec{y} , potem je

$$\frac{\vec{x} \cdot \vec{y}}{||\vec{x}|| ||\vec{y}||} = \cos \phi$$

1.13 Vektorski produkt:

$$\vec{a} \times \vec{b} = (a_2 b_3 - a_3 b_2) \mathbf{i} + (a_3 b_1 - a_1 b_3) \mathbf{j} + (a_1 b_2 - a_2 b_1) \mathbf{k}$$

Lastnosti vektorskega produkta

- $\vec{a} \times (\vec{b} + \vec{c}) = \vec{a} \times \vec{b} + \vec{a} \times \vec{c}$ (aditivnost)
- $\vec{b} \times \vec{a} = -\vec{a} \times \vec{b}$ (!komutativnost)
- $(a\vec{a}) \times \vec{b} = a(\vec{a} \times \vec{b}) = \vec{a} \times (a\vec{b})$ (homogenost)
- $\vec{a} \times \vec{a} = 0$
- $\vec{a} \times \vec{b}$ je \perp na vektorja \vec{a} in \vec{b}
- $||\vec{a} \times \vec{b}|| = ||\vec{a}|| ||\vec{b}|| \sin \phi$
- Dolžina vektorskega produkta je ploscina paralelograma, katerega vektorja oklepata

1.14 Mesani produkt $(\vec{a}, \vec{b}, \vec{c})$ vektorjev \vec{a}, \vec{b} in \vec{c} v R^3 je skalarni produkt vektorjev $\vec{a} \times \vec{b}$ in \vec{c} :

$$(\vec{a}, \vec{b}, \vec{c}) = (\vec{a} \times \vec{b}) \cdot \vec{c}$$

Lastnosti mesanega produkta

- $(\vec{a}, \vec{b}, \vec{c}) = (\vec{b}, \vec{c}, \vec{a}) = (\vec{c}, \vec{a}, \vec{b})$
- $(x\vec{a}, \vec{b}, \vec{c}) = x(\vec{a}, \vec{b}, \vec{c})$ (homogenost)
- $(\vec{a}, \vec{u} + \vec{v}, \vec{c}) = (\vec{a}, \vec{u}, \vec{c}) + (\vec{a}, \vec{v}, \vec{c})$
- Absolutna vrednost mesanega produkta $(\vec{a}, \vec{b}, \vec{c})$ je enaka prostornini paralepipeda

Premice v R^3

Premico določata smerni vektor $\vec{p} = [a, b, c]^T$ in točka $A(x_0, y_0, z_0)$.

- Parametrična oblika: $\vec{r} = \vec{r}_A + t\vec{p}, t \in R$
- Kanonična oblika: $\frac{x - x_0}{a} = \frac{y - y_0}{b} = \frac{z - z_0}{c}$

Ravnine v R^3

Ravnina z normalo $\vec{n} = [a, b, c]^T$ skozi točko $A(x_0, y_0, z_0)$ ima enačbo

$$(\vec{r} - \vec{r}_A) \cdot \vec{n} = 0$$

oziroma

$$ax + by + cz = d$$

Razdalje

Razdalja od točke P do ravnine, v kateri leži točka A :

$$\cos \phi = \frac{\vec{n} \cdot (\vec{r}_P - \vec{r}_A)}{||\vec{n}|| ||\vec{r}_P - \vec{r}_A||} \text{ oz. } d = \frac{|\vec{n} \cdot (\vec{r}_P - \vec{r}_A)|}{||\vec{n}||}$$

Razdalja od točke P do premice, katere gre skozi točko A :

$$d = \frac{||\vec{c} \times (\vec{r}_P - \vec{r}_A)||}{||\vec{c}||}$$

Projekcije vektorjev

Naj bo $proj_{\vec{a}}\vec{b} = \vec{x}$ projekcija vektorja \vec{b} na vektor \vec{a} . Izračunamo jo po sledeci formuli:

$$proj_{\vec{a}}\vec{b} = \frac{\vec{a}\vec{b}}{\vec{a}\vec{a}}\vec{a}$$

1.15 Matrika dimenzije $m \times n$ je tabela $m \times n$ števil, urejenih v m vrstic in n stolpcev:

$$A^{m \times n} = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1n} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & x_{m3} & \dots & x_{mn} \end{bmatrix}$$

1.16 Matrika, katere elementi so enaki nič povsod zunaj glavne diagonale, se imenuje diagonalna matrika. Za diagonalno matriko je $a_{ij} = 0$, kadarkoli velja $i \neq j$

1.17 Matrika $A^{n \times n}$ je spodnjetrokotna, kadar so vsi elementi nad glavno diagonalo enaki 0:

$$a_{ij} = 0 \text{ kadar je } i < j$$

1.18 Matrika $A^{n \times n}$ je zgornjetrokotna, kadar so vsi elementi pod glavno diagonalo enaki 0:

$$a_{ij} = 0 \text{ kadar je } i > j$$

1.19 Matrika je trikotna, če je zgornjetrokotna ali spodnjetrokotna.

1.20 Dve matriki A in B sta enaki natanko takrat, kadar imata enaki dimenziji in kadar so na istih mestih v obeh matrikah enaki elementi:

$$A^{m \times n} = B^{p \times q} \implies m = p \text{ in } n = q, \\ a_{ij} = b_{ij} \text{ za vsak } i = 1, \dots, m \text{ in } j = 1, \dots, n$$

1.21 Produkt matrike s skalarjem dobimo tako, da vsak element matrike pomnožimo s *skalarjem*

$$aA^{m \times n} = \begin{bmatrix} ax_{11} & ax_{12} & ax_{13} & \dots & ax_{1n} \\ ax_{21} & ax_{22} & ax_{23} & \dots & ax_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ ax_{m1} & ax_{m2} & ax_{m3} & \dots & ax_{mn} \end{bmatrix}$$

1.22 Vsoto dveh matrik enake dimenzije dobimo tako, da seštejemo istolezne elemente obeh matrik:

$$A + B = \begin{bmatrix} a_{11} + b_{11} & ax_{12} + b_{12} & \dots & ax_{1n} + b_{1n} \\ a_{21} + b_{21} & ax_{22} + b_{22} & \dots & ax_{2n} + b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} + b_{m1} & ax_{m2} + b_{m3} & \dots & ax_{mn} + b_{mn} \end{bmatrix}$$

Osnovne matricne operacije

- $A + B = B + A$ (komutativnost)
- $(A + B) + C = A + (B + C)$ (asociativnost)
- $a(A + B) = aA + aB$ (množenje s skalarjem)
- $A + (-A) = 0$
- $x(yA) = (xy)A$ in $1 \cdot A = A$

1.23 Transponirana matrika k matriki A reda $m \times n$ je matrika reda $n \times m$

$$A = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix} \\ A^T = \begin{bmatrix} x_{11} & x_{21} & \dots & x_{m1} \\ x_{12} & x_{22} & \dots & x_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n} & x_{2n} & \dots & x_{mn} \end{bmatrix}$$

Lastnosti transponiranja matrik

- $(A + B)^T = A^T + B^T$
- $(A \cdot B)^T = B^T \cdot A^T$
- $(xA)^T = xA^T$
- $(A^T)^T = A$

1.24 Produkt matrike A in vektorja \vec{x} je linearna kombinacija stolpcev matrike A , utezi linearne kombinacije so komponente vektorja \vec{x} :

$$A\vec{x} = \begin{bmatrix} \vec{u} & \vec{v} & \vec{w} \end{bmatrix} \cdot \begin{bmatrix} a \\ b \\ c \end{bmatrix} = a\vec{u} + b\vec{v} + c\vec{w}$$

1.25 Produkt vrstice \vec{x} z matriko A je linearna kombinacija vrstic matrike A , koeficienti linearne kombinacije so komponente vrstice \vec{y} :

$$\vec{y} \cdot A = [y_1, y_2, y_3] \cdot \begin{bmatrix} \vec{u} \\ \vec{v} \\ \vec{w} \end{bmatrix} = \begin{bmatrix} y_1\vec{u} \\ y_2\vec{v} \\ y_3\vec{w} \end{bmatrix}$$

1.26 Produkt matrik A in B je matrika, katere stolpci so zaporedoma produkti matrike A s stolpci matrike B :

$$AB = A [b_1, b_2, \dots, b_n] = [Ab_1, Ab_2, \dots, Ab_n]$$

1.27 Element c_{ij} v i -ti vrstici in j -tem stolpcu produkta $C = AB$ je skalarni produkt i -te vrstice A in j -tega stolpca matrike B

$$c_{ij} = \sum_{k=1}^n a_{ik}b_{kj}$$

1.28 Produkt matrik A in B je matrika, katere vrstice so zaporedoma produkti vrstic matrike A z matriko B :

$$[i\text{-ta vrstica } A] B = [i\text{-ta vrstica } AB]$$

Lastnosti matricnega produkta

- $AB \neq BA$ (!komutativnost)
- $(xA)B = x(AB) = A(xB)$ (homogenost)
- $C(A + B) = CA + CB$ (distributivnost)
- $A(BC) = (AB)C$ (asociativnost)
- $(AB)^T = B^T A^T$

V splošnem; komutativnost matricnega množenja velja samo, ko sta matriki diagonalizabilni.

1.29 Vrstice matrike A z n stolpci naj bodo a^1, \dots, a^n , stolpci matrike B z n vrsticami pa b_1, \dots, b_n . Potem je

$$AB = a^1 b_1 + \dots + a^n b_n$$

1.30 Če delitev na bloke v matriki A ustreza delitvi v matriki B , potem lahko matriki pomnožimo blocno:

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}$$

1.31 Kvadratna matrika I_k reda $k \times k$, ki ima vse diagonalne elemente enake 1, vse ostale elemente pa 0 ima lastnost, da za vsako matriko A reda $m \times n$ velja $AI_n = A$ in $I_m A = A$. Matrika I_k se imenuje enotska ali identična matrika.

$$I_k = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

2 Sistemi linearnih enačb

2.1 Kvadratna matrika A je obrnljiva, če obstaja taka matrika A^{-1} , da je

$$AA^{-1} = I \text{ in } A^{-1}A = I$$

Matrika A^{-1} (če obstaja) se imenuje matriki A inverzna matrika. Matrika, ki ni obrnljiva, je singularna. Matrika **NI** obrnljiva, kadar je $\text{rang}(A) < n$!

2.2 Kvadratna matirka reda n je obrnljiva natanko tedaj, ko pri gaussovi eliminaciji dobimo n pivotov.

2.3 Vsaka obrnljiva matrika ima eno samo inverzno matriko.

2.4 Inverzna matrika inverzne matrike A^{-1} je matrika A

$$(A^{-1})^{-1} = A$$

2.5 Če je matrika A obrnljiva, potem ima sistem enačb $A\vec{x} = \vec{b}$ edino resitev $\vec{x} = A^{-1}\vec{b}$

2.6 Če obstaja nenicelna resitev \vec{x} enačbe $A\vec{x} = \vec{0}$, matrika A ni obrnljiva (je singularna).

2.7 Če sta matirki A in B istega reda obrnljivi, je obrnljiv tudi produkt $A \cdot B$ in

$$(A \cdot B)^{-1} = B^{-1} \cdot A^{-1}$$

Pozor! Pravilo

$$(AB)^p = A^p B^p$$

velja le v primeru, ko matriki A in B komutirata, torej $AB = BA$.

2.8 Inverz transponirane matrike je transponirana matrika inverza

$$(A^T)^{-1} = (A^{-1})^T$$

2.9 Inverz diagonalne matrike z diagonalnimi elementi a_{ii} je diagonalna matrika, ki ima na diagonalni elemente a_{ii}^{-1}

$$\begin{bmatrix} a_{11} & & 0 \\ & \ddots & \\ 0 & & a_{nn} \end{bmatrix} = \begin{bmatrix} a_{11}^{-1} & & 0 \\ & \ddots & \\ 0 & & a_{nn}^{-1} \end{bmatrix}$$

2.10 Za izračun inverza matrike A , uporabimo gaussovo eliminacijo nad matriko $[A|I]$

$$[A|I] = [I|A^{-1}]$$

2.11 Matrika A je simetrična $\Leftrightarrow A^T = A$. Za elemente a_{ij} simetrične matirke velja $a_{ij} = a_{ji}$. Za simetrično matriko vedno velja, da je kvadratna $A \in R^{n \times n}$.

2.12 Če je matrika A simetrična in obrnljiva, je tudi A^{-1} simetrična.

2.13 Če je R poljubna (lahko tudi pravokotna) matrika, sta $R^T R$ in RR^T simetrični matriki.

3 Vektorski prostori

3.1 Realni vektorski prostor V je množica "vektorjev" skupaj z pravili za

- seštevanje vektorjev,
- množenje vektorja z realnim številom (skalarjem)

Ce sta \vec{x} in \vec{y} poljubna vektorja v V , morajo biti v V tudi

- vsota $\vec{x} + \vec{y}$ in
- produkti $\alpha\vec{x}$ za vse $\alpha \in R$

V vektorskem prostoru V morajo biti tudi VSE linearne kombinacije $\alpha\vec{x} + \beta\vec{y}$

Pravila za operacije v vektorskih prostorih

Operaciji seštevanja vektorjev in množenja vektorja s skalarjem v vektorskem prostoru morajo zadoscati naslednjim pravilom:

- $\vec{x} + \vec{y} = \vec{y} + \vec{x}$ (komutativnost)
- $\vec{x} + (\vec{y} + \vec{z}) = (\vec{x} + \vec{y}) + \vec{z}$ (asociativnost)
- obstaja en sam nenicelni vektor $\vec{0}$, da velja $\vec{x} + \vec{0} = \vec{x}$
- za vsak \vec{x} obstaja natanko en $-\vec{x}$, da je $\vec{x} + (-\vec{x}) = \vec{0}$
- $1 \cdot \vec{x} = \vec{x}$
- $(\alpha\beta)\vec{x} = \alpha(\beta\vec{x})$
- $\alpha(\vec{x} + \vec{y}) = \alpha\vec{x} + \alpha\vec{y}$ (distributivnost)
- $(\alpha + \beta)\vec{x} = \alpha\vec{x} + \beta\vec{x}$

3.2 Podmnožica U vektorskega prostora V je *vektorski podprostor*, če je za vsak par vektorjev \vec{x} in \vec{y} iz U in vsako realno število α tudi

- $\vec{x} + \vec{y} \in U$ in
- $\alpha\vec{x} \in U$.

3.3 Mnozica vektorjev U je vektorski podprostor natanko tedaj, ko je vsaka linearna kombinacija vektorjev iz U tudi v U .

Lastnosti vektorskih podprostorov

- Vsak vektorski podprostor nujno vsebuje nicelni vektor $\vec{0}$
- Presek dveh podprostorov vektorskega podprostora je tudi podprostor

3.4 Stolpicni prostor $C(A)$ matrike $A \in R^{m \times n}$ je tisti podprostor vektorskega prostora R^m , ki vsebuje natanko vse linearne kombinacije stolpcev matrike A .

Izračunamo ga tako, da matriko A transponiramo in izvedemo operacijo gaussove eliminacije nad A^T . Vrstice katere ostanejo po gaussovi eliminaciji so linearno neodvisni vektorji, kateri tvorijo stolpicni prostor matrike A , $C(A)$. *neformalno: linearna ogrinjaca stolpcev matrike (npr. če imas 5 stolpcev pa lahko 2 zapises kot linearno kombinacijo ostalih 3 bo imel column space 3 elemente)*

3.5 Sistem linearnih enačb $A\vec{x} = \vec{b}$ je resljiv natanko tedaj, ko je vektor $\vec{b} \in C(A)$

3.6 Naj bo matrika $A \in R^{m \times n}$. Mnozica resitev homogenega sistema linearnih enačb je podprostor v vektorskem prostoru R^n .

3.7 Mnozica vseh resitev sistema linearnih enačb $A\vec{x} = \vec{0}$ se imenuje nicelni prostor matirke A . Oznacujemo ga z $N(A)$. *neformalno: množica vektorjev, ki se z neko matriko zmnožijo v nicelni vektor. Matriko A samo eliminiras po gausu in nato dobljene resitve enacis z 0.*

3.8 Če je matrika A kvadratna in obrnljiva, potem $N(A)$ vsebuje samo vektor $\vec{0}$

3.9 Matrika ima *stopnicasto* obliko, kadar se vsaka od njenih vrstic začne z vsaj eno ničlo več kot prejšnja vrstica.

3.10 Prvi element, različen od nič v vsaki vrstici, je *pivot*. Število pivotov v matriki se imenuje rang matrike. Rang matrike A zapisemo kot $\text{rang}(A)$.

3.11 Rang matrike ni večji od števila vrstic in ni večji od števila stolpcev matrike.

3.12

Število prostih neznanek matrike = št. stolpcev - rang matrike

3.13

1. Visoka in ozka matrika ($m > n$) ima poln stolpicni rang, kadar je $\text{rang}(A) = n$

2. Nizka in široka matrika ($m < n$) ima poln vrsticni rang, kadar je $\text{rang}(A) = m$

3. Kvadratna matrika ($n = m$) ima poln rang, kadar je $\text{rang}(A) = m = n$

3.14 Za vsako matriko A s polnim stolpicnim rangom $r = n \leq m$, velja:

1. Vsi stolpci A so pivotni stolpci
2. Sistem enacb $A\vec{x} = \vec{0}$ nima prostih neznank, zato tudi nima posebnih rešitev
3. Nicelni prostor $N(A)$ vsebuje le nicelni vektor $N(A) = \{\vec{0}\}$
4. Kadar ima sistem enacb $A\vec{x} = \vec{b}$ rešitev (kar ni vedno res!), je rešitev ena sama
5. Reducirana vrsticna oblika matrike (A) se da zapisati kot

$$R = \begin{bmatrix} I \\ 0 \end{bmatrix} \begin{bmatrix} n \times n \text{ enotska matrika} \\ m - n \text{ vrstic samih nicel} \end{bmatrix}$$

3.15 Za vsako matriko A s polnim vrsticnim rangom $r = m \leq n$ velja:

1. Vse vrstice so pivotne, ni prostih vrstic in U (stopnicasta oblika) in R (reducirana stopnicasta oblika) nimata nicelnih vrstic
2. Sistem enacb $A\vec{x} = \vec{b}$ je resljiv za vsak vektor \vec{b}
3. Sistem $A\vec{x} = \vec{b}$ ima $n - r = n - m$ prostih neznank, zato tudi prav toliko posebnih rešitev
4. Stolpicni prostor $C(A)$ je ves prostor R^m

3.16 Za vsako kvadratno matriko A polnega ranga ($\text{rang}(A) = m = n$) velja:

1. Reducirana vrsticna oblika matrike A je enotska matrika
2. Sistem enacb $A\vec{x} = \vec{b}$ ima natancno eno rešitev za vsak vektor desnih strani \vec{b}
3. Matrika A je obrnljiva
4. Nicelni prostor matrike A je samo nicelni vektor $N(A) = \{\vec{0}\}$
5. Stolpicni prostor matrike A je cel prostor $C(A) = R^m$

3.17 Vektorji $\vec{x}_1, \dots, \vec{x}_n$ so linearno neodvisni, ce je

$$0\vec{x}_1 + 0\vec{x}_2 + \dots + 0\vec{x}_n$$

edina njihova linearna kombinacija, ki je enaka vektorju $\vec{0}$. Vektorji $\vec{x}_1, \dots, \vec{x}_n$ so linearno odvisni, ce niso linearno neodvisni.

3.18 Ce so vektorji *odvisni*, lahko vsaj enega izrazimo z ostalimi.

3.19 Ce je med vektorji $\vec{u}_1, \dots, \vec{u}_n$ tudi nicelni vektor, so vektorji *linearno odvisni*.

3.20 Vsaka množica n vektorjev iz R^n je odvisna, kadar je $n > m$.

3.21 Stolpci matrike A so linearno neodvisni natanko tedaj, ko ima homogena enacba $A\vec{x} = \vec{0}$ edino rešitev $\vec{x} = \vec{0}$.

3.22 Kadar je $\text{rang}(A) = n$, so stolpci matrike $A \in R^{m \times n}$ linearno neodvisni. Kadar je pa $\text{rang}(A) < n$, so stolpci matrike $A \in R^{m \times n}$ linearno odvisni.

3.23 Kadar je $\text{rang}(A) = m$, so vrstice matrike $A \in R^{m \times n}$ linearno neodvisne. Kadar je pa $\text{rang}(A) < m$, so vrstice matrike $A \in R^{m \times n}$ linearno odvisne.

3.24 Vrsticni prostor matrike A je podprostor v R^n , ki ga razpenjajo vrstice matrike A.

3.25 Vrsticni prostor matrike A je $C(A^T)$, stolpicni prostor matrike A^T .

3.26 Baza vektorskega prostora je množica vektorjev, ki

1. je linearno neodvisna in

2. napolni cel prostor.

3.27 Vsak vektor iz vektorskega prostora lahko na en sam način izrazimo kot linearno kombinacijo baznih vektorjev.

3.28 Vektorji $\vec{x}_1, \dots, \vec{x}_n$ so baza prostora R^n natanko tedaj, kadar je matrika, sestavljena iz stolpcev $\vec{x}_1, \dots, \vec{x}_n$, obrnljiva.

3.29 Prostor R^n ima za $n > 0$ neskončno mnogo različnih baz.

3.30 Ce sta množici vektorjev $\vec{v}_1, \dots, \vec{v}_m$ in $\vec{u}_1, \dots, \vec{u}_n$ obe bazi istega vektorskega prostora, potem je $m = n \implies$ vse baze istega vektorskega prostora imajo isto število vektorjev.

3.31 Dimenzija vektorskega prostora je število baznih vektorjev.

3.32 Dimenziji stolpicnega prostora $C(A)$ in vrsticnega prostora $C(A^T)$ sta enaki rang matrike A

$$\dim(C(A)) = \dim(C(A^T)) = \text{rang}(A).$$

3.33 Dimenzija nicelnega prostora $N(A)$ matrike A z n stolpci in ranga r je enaka $\dim(N(A)) = n - r$.

3.34 Stolpicni prostor $C(A)$ in vrsticni prostor $C(A^T)$ imata oba dimenzijo r. Dimenzija nicelnega prostora $N(A)$ je $n - r$, Dimenzija levega nicelnega prostora $N(A^T)$ pa je $m - r$.

3.35 Vsako matriko ranga 1 lahko zapisemo kot produkt (stolpcnega) vektorja z vrsticnim vektorjem $A = \vec{u}\vec{v}^T$.

4 Linearne preslikave

4.1 Preslikava $A : U \rightarrow V$ je linearna, ce velja

1. aditivnost: $A(\vec{u}_1 + \vec{u}_2) = A\vec{u}_1 + A\vec{u}_2$ za vse $\vec{u}_1, \vec{u}_2 \in U$,
2. homogenost: $A(\alpha\vec{u}) = \alpha(A\vec{u})$ za vse $\alpha \in R$ in $\vec{u} \in U$.

Oziroma v enem koraku:

$$A(\alpha\vec{u}_1 + \beta\vec{u}_2) = \alpha A(\vec{u}_1) + \beta A(\vec{u}_2).$$

Pozor! Preslikava ni linearna, ce $A(\vec{0}) \neq \vec{0}$.

4.2 Preslikava $A : U \rightarrow V$ je linearna natanko tedaj, ko velja

$$A(\alpha_1\vec{u}_1 + \alpha_2\vec{u}_2) = \alpha_1 A\vec{u}_1 + \alpha_2 A\vec{u}_2$$

za vse $\alpha_1, \alpha_2 \in R$ in vse $\vec{u}_1, \vec{u}_2 \in U$.

4.3 Ce je A *linearna preslikava*, je $A\vec{0} = \vec{0}$.

4.4 Naj bo $A : U \rightarrow V$ linearna preslikava in $\sum_{i=1}^k \alpha_i \vec{u}_i$ linearna kombinacija vektorjev. Potem je $A(\sum_{i=1}^k \alpha_i \vec{u}_i) = \sum_{i=1}^k \alpha_i A\vec{u}_i$.

4.5 Naj bo $\beta = \{\vec{u}_1, \dots, \vec{u}_n\}$ baza za vektorski prostor U. Potem je linearna preslikava $A : U \rightarrow V$ natanko določena, ce poznamo slike baznih vektorjev.

4.6 Naj bo $\beta = \{\vec{u}_1, \dots, \vec{u}_n\}$ baza za U in $\{\vec{v}_1, \dots, \vec{v}_n\}$. Potem obstaja natanko ena linearna preslikava $A : U \rightarrow V$, za katero je $A\vec{u}_i = \vec{v}_i$ za $i = 1, 2, \dots, n$.

4.7 Naj bo $A : U \rightarrow V$ linearna preslikava. Potem množico

$$\ker A = \{\vec{u} \in U; A\vec{u} = \vec{0}\}$$

imenujemo *jedro* linearne preslikave. Ker je $A\vec{0} = \vec{0}$, je $\vec{0} \in \ker A$ za vse A. Zato je jedro vedno neprazna množica. *Ce je matrika A ϕ enotska preslikava za ϕ , potem velja*

$$\ker \phi = N(A).$$

4.8 Jedro linearne preslikave $A : U \rightarrow V$ je vektorski podprostor v U.

4.9 Množico

$$\text{im } A = \{\vec{v} \in V; \text{ obstaja tak } \vec{u} \in U, \text{ da je } \vec{v} = A\vec{u}\}$$

imenujemo *slika* linearne preslikave $A : U \rightarrow V$. *Ce je matrika A ϕ enotska preslikava za ϕ , potem velja*

$$\text{im}\phi = C(A).$$

4.10 Če je $A : U \rightarrow V$ linearna preslikava, potem je njena slika $\text{im } A$ vektorski podprostor v V .

4.11 Če je $A : U \rightarrow V$ linearna preslikava, in je rang matrike te preslikave v standardni bazi poln, potem lahko sklepamo, da ima ta preslikava **trivialno jedro**.

5 Ortogonalnost

5.1 Podprostora U in V vektorskega prostora sta med seboj ortogonalna, če je vsak vektor $\vec{u} \in U$ ortogonalen na vsak vektor $\vec{v} \in V$.

5.2 Za vsako matriko $A \in R^{m \times n}$ velja:

1. Nicelni prostor $N(A)$ in vrsticni prostor $C(A^T)$ sta ortogonalna podprostora R^n
2. Levi nicelni prostor $N(A^T)$ in stolpčni prostor $C(A)$ sta ortogonalna podprostora prostora R^m .

5.3 Ortogonalni komplement V^\perp podprostora V vsebuje VSE vektorje, ki so ortogonalni na V .

5.4 Naj bo A matrika dimenzije $m \times n$.

- Nicelni prostor $N(A)$ je ortogonalni komplement vrsticnega prostora $C(A^T)$ v prostoru R^n
- Levi nicelni prostor $N(A^T)$ je ortogonalni komplement stolpčnega prostora $C(A)$ v prostoru R^m .

krajse:

$$N(A) = C(A^T)^\perp \\ N(A^T) = C(A)^\perp$$

tukaj lahko vedno pomnožimo s komplementom, da dobimo npr.

$$N(A)^\perp = C(A^T)$$

dodatek:

$$\dim N(A) = \text{st.stolpcev} - \text{rang}(A) \\ \dim N(A^T) = \text{st.vrstic} - \text{rang}(A) \\ \dim C(A) = \dim C(A^T) = \text{rang}(A)$$

5.5 Za vsak vektor \vec{y} v stolpčnem prostoru $C(A)$ obstaja v vrsticnem prostoru $C(A^T)$ en sam vektor \vec{x} , da je $A\vec{x} = \vec{y}$.

5.6 Če so stolpci matrike A linearno neodvisni, je matrika $A^T A$ obrnljiva.

5.7 Matrika P je projekcijska, kadar

- je simetrična: $P^T = P$ in

- velja $P^2 = P$.

5.8 Če je P projekcijska matrika, ki projecira na podprostor U , potem je $I - P$ projekcijska matrika, ki projecira na U^\perp , ortogonalni komplement podprostora U .

5.9 Vektorji $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$ so ortonormirani kadar so ortogonalni in imajo vsi dolžino 1, torej

$$\vec{q}_i^T \vec{q}_j = \begin{cases} 0 & \text{ko je } i \neq j \text{ pravokotni vektorji} \\ 1 & \text{ko je } i = j \text{ enotski vektorji} \end{cases}$$

za matriko $Q = [\vec{q}_1, \vec{q}_2 \dots \vec{q}_n]$ velja $Q^T Q = I$.

5.10 Vektorji $\vec{q}_1, \dots, \vec{q}_n$ naj bodo ortonormirani v prostoru R^m . Potem za matriko

$$Q = [\vec{q}_1 \vec{q}_2 \dots \vec{q}_n]$$

velja, da je $Q^T Q = I_n$ enotska matrika reda n .

5.11 Matrika Q je ortogonalna, kadar je

1. kvadratna in

2. ima ortonormirane stolpce.

5.12 Če je Q ortogonalna matirka, potem je obrnljiva in

$$Q^{-1} = Q^T \\ \dim U^\perp = n - \dim U \\ (U^\perp)^\perp = U$$

5.13 Množenje z ortogonalno matriko ohranja dolžino vektorjev in kote med njimi. Če je Q ortogonalna matrika, potem je

$$\|Q\vec{x}\| = \|\vec{x}\| \text{ za vsak vektor } \vec{x} \text{ in} \\ (Q\vec{x})^T Q\vec{y} = \vec{x}^T \vec{y} \text{ za vsak vektor } \vec{x} \text{ in } \vec{y}$$

5.14 Če sta Q_1 in Q_2 ortogonalni matriki, je tudi produkt $Q = Q_1 Q_2$ ortogonalna matrika.

5.15 Gram-Schmidtova ortogonalizacija. Za vhod uporabimo Linearno ogrinjaco linearno neodvisnih vektorjev. Po gram-schmidtovi ortogonalizaciji pa dobimo paroma ortogonalne vektorje. Postopek:

$$\vec{u}_1 = \vec{v}_1 \\ \vec{u}_2 = \vec{v}_2 - \text{proj}_{\vec{u}_1} \vec{v}_2 \\ \vec{u}_3 = \vec{v}_3 - \text{proj}_{\vec{u}_1} \vec{v}_3 - \text{proj}_{\vec{u}_2} \vec{v}_3 \\ \vdots$$

Po tem postopku dobimo paroma ortogonalne vektorje po Gram-Schmidtovi ortogonalizaciji.

5.16 QR Razcep: Iz linearno neodvisnih vektorjev a_1, \dots, a_n z *Gram-Schmidtovo* ortogonalizacijo dobimo ortonormirane vektorje q_1, \dots, q_n . Matriki A in Q s temi stolpci zadoscajo enacbi $A = QR$, kjer je R zgornjetrikotna matrika.

- Najprej z Gram-Schmidtovo ortogonalizacijo poiscemo linearno neodvisne vektorje matrike A

- Vektorje normiramo in jih zapisemo v matriko Q .

- Matriko R dobimo tako, da matriko Q^T pomnožimo z matriko A

$$R = Q^T A$$

Tako smo prisli do vseh elementov v QR razcepu matrike A .

Sedaj ko imamo izracunane vse elemente lahko zapisemo se projekcijsko matriko. To je matrika pravokotne projekcije na $C(Q) = C(A)$. Njen izracun je preprost:

$$QQ^T = \text{pravokotna projekcija na } C(Q) = C(A)$$

Sedaj lahko to projekcijsko matriko pomnožimo z desne s poljubnim vektorjem in ugotovimo kam se preslika v prostoru $C(A)$. V nasprotnem primeru, ce bi pa zeleli imeti projekcijsko matriko, s katero bi radi videli kam se vektor preslika v prostoru $N(A^T)$, bi pa od identicne matrike odsteli projekcijsko matriko za $C(Q)$.

$$I - QQ^T = \text{pravokotna projekcija na } C(A)^\perp = N(A^T)$$

5.17 Vektorski prostor ι je množica vseh neskončnih zaporedij \vec{u} s končno dolžino

$$\|\vec{u}\|^2 = \vec{u} \cdot \vec{u} = \vec{u}_1^2 + \vec{u}_2^2 + \dots < \infty$$

5.18 Predoloceni sistemi

$$A^T A \begin{bmatrix} a \\ b \end{bmatrix} = A^T \vec{f}$$

Kjer je A matrika sistemov linearnih enacb in \vec{f} vektor pricakovanih resitev po gaussovi eliminaciji zgornje enacbe, dobimo spremenljivke, ki predstavljajo najboljso aproksimacijo vseh kombinaicij rezultatov in vhodnih spremenljivk.

6 Determinante

6.1 Determinanta enotske matirke je $\det(I) = 1$.

$$\begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1 \text{ in } \begin{vmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{vmatrix} = 1.$$

6.2 Determinanta spremeni predznak, ce med seboj zamenjamo dve vrstici.

Dodatna lastnost:

$$\begin{vmatrix} A & C \\ 0 & B \end{vmatrix} = \det(A) \det(B)$$

6.3 Determinanta je linearna funkcija vsake vrstice posebej. To pomeni, da se

1. determinanta pomnozi s faktorjem t , ce eno vrstico determinante (vsak element v tej vrstici) pomnozimo s faktorjem t .

$$\begin{vmatrix} ta & tb \\ c & d \end{vmatrix} = t \begin{vmatrix} a & b \\ c & d \end{vmatrix}$$

2. determinanta je vsota dveh determinant, ki se razlikujeta le v eni vrstici, ce je v provitni determinanti ta vrstica vsota obeh vrstic, ostale vrstice pa so enake v vseh treh determinantah.

$$\begin{vmatrix} a+a' & b+b' \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \begin{vmatrix} a' & b' \\ c & d \end{vmatrix}$$

Pozor! Kadar mnozimo matriko A s skalarjem t , se vsak element matrike pomnozi s skalarjem. Ko racunamo determinanto produkta matirke s skalarjem tA , skalar t izpostavimo iz vsake vrstice posebej, zato je $\det(tA) = t^n \det(A)$, kjer je n stevilo vrstic (ali stolpcev) determinante.

6.4 Matrika, ki ima dve enaki vrstici, ima determinanto enako 0.

6.5 Ce v matriki od poljubne vrstice odstejemo mnogokratnik neke druge vrstice, se njena determinanta ne spremeni.

6.6 Naj bo A poljubna kvadratna matirka $n \times n$ in U njena vrsticno-stopnicasta oblika, ki jo dobimo z *Gaussovo eliminacijo*. Potem je

$$\det(A) = \pm \det(U).$$

6.7 Determinanta, ki ima vrstico samih nicel, je enaka 0.

6.8 Determinanta trikotne matrike A je produkt diagonalnih elementov:

$$\det(A) = a_{11}a_{22} \dots a_{nn}.$$

6.9 Determinanta singularne matrike je enaka 0, determinanta obrnljive matrike je razlicna od 0.

6.10 Determinanta produkta dveh matrik je enaka produktu determinant obeh matrik:

$$\det(AB) = \det(A)\det(B).$$

6.11 Determinanta inverzne matrike je enaka

$$\det(A^{-1}) = 1/\det(A)$$

in determinanta potence A^n matrike A je

$$\det(A^n) = (\det(A))^n$$

ter determinanta transponirane matrike je enaka determinanti originalne matrike, saj ko naredimo razvoj po vrsticah, pridemo do enakih elementov po diagonalni.

$$\det(A) = \det(A^T).$$

6.12 Transponirana matrika A^T ima isto determinanto kot A .

6.13 Recap dovoljenih operacij nad determinanto

1. Ce zamenjamo dve vrstici, se **spremeni** predznak determinante
2. Vrednost determinante se ne spremeni, ce neki vrstici pristevamo poljuben veckratnik katerekoli druge vrstice.
3. Ce vse elemente neke vrstice pomnozimo z istim stevilom α , se vrednost determinante pomnozi z α .

6.14 Vsaka lastnost, ki velja za vrstice determinante, velja tudi za njene **stolpce**. Med drugim:

- Determinanta spremeni predznak, ce med seboj zamenjamo dva stolpca
- Determinanta je enaka 0, ce sta dva stolpca enaka
- Determinanta je enaka 0, ce so v vsaj enem stolpcu same nicle.

6.15 (kofaktorska formula) Ce je A kvadratna matrika reda n , njeno determinanto lahko izracunamo z razvojem po $i - ti$ vrstici

$$\det(A) = a_{i1}C_{i1} + a_{i2}C_{i2} + \dots + a_{in}C_{in}.$$

Kofaktorje C_{ij} izracunamo kot $C_{ij} = (-1)^{i+j}D_{ij}$, kjer je D_{ij} determinanta, ki jo dobimo, ce v A izbrisemo i -to vrstico in j -ti stolpec.

6.16 Inverzna matrika A^{-1} matrike A je transponirana matrika kofaktorjev, deljena z determinanto $|A|$:

$$A^{-1} = \frac{C^T}{\det(A)},$$

kjer je C matrika kofaktorjev matrike A .

6.17 Ploscina paralelograma, dolocenega z vektorjema \vec{a} in $\vec{b} \in \mathbb{R}^2$ je enaka $\det([\vec{a}\vec{b}])$, to je absolutni vrednosti determinante s stolpcema \vec{a} in \vec{b} .

6.18 Mesani produkt vektorjev \vec{a} in \vec{b} in \vec{c} je enak determinanti matrike, ki ima te tri vektorje kot stolpce.

6.19 Naj bo A matrika $\mathbb{R}^{n \times n}$

$$A \text{ je obrnljiva} \iff \det A \neq 0$$

$$A^{-1} \text{ ne obstaja} \iff \det A = 0$$

7 L. vrednosti in vektorji

7.1 Vektor $\vec{x} \neq \vec{0}$, za katerega je $A\vec{x} = \lambda\vec{x}$ lastni vektor. Stevilo λ je lastna vrednost. **Pozor!** Nicelni vektor $\vec{0}$ ne more biti lastni vektor. Lahko pa je lastna vrednost enaka 0.

7.2 Ce ima matrika A lastno vrednost λ in lastni vektor \vec{x} , potem ima matrika A^2 lastno vrednost λ^2 in isti lastni vektor \vec{x} .

7.3 Ce ima matrika A lastno vrednost λ in lastni vektor \vec{x} , potem ima matrika A^k lastno vrednost λ^k in isti lastni vektor \vec{x} .

7.4 Ce ima matrika A lastno vrednost λ in lastni vektor \vec{x} , potem ima inverzna matrika lastno vrednost $1/\lambda$ in isti lastni vektor \vec{x} .

7.5 Sled kvadratne matrike A reda n je vsota njenih diagonalnih elementov.

$$\text{sled}(A) = \sum_{i=1}^n a_{ii} = a_{11} + \dots + a_{nn}.$$

7.6 Sled matrike je enaka vsoti vseh lastnih vrednosti, stetih z njihovo veckratnostjo. Ce so $\lambda_1, \dots, \lambda_n$ lastne vrednosti matrike reda n , potem je sled enaka *vsoti*

$$\text{sled}(A) = \sum_{i=1}^n \lambda_i = \lambda_1 + \dots + \lambda_n,$$

determinanta matrike pa *produktu* lastnih vrednosti

$$\det(A) = \prod_{i=1}^n \lambda_i = \lambda_1 \dots \lambda_n.$$

Lastnosti sledi Za matrike $A, B, P \in \mathbb{R}^{n \times n}$ velja

1. $\text{tr}(\alpha A) = \alpha \text{tr}(A)$,
2. $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$,
3. $\text{tr}(A^T) = \text{tr}(A)$,
4. $\text{tr}(AB) = \text{tr}(BA)$,
5. $\text{tr}(PAP^{-1}) = \text{tr}(A)$ za vsako obrnljivo matriko P .
6. $\text{tr}(ABP) = \text{tr}(APB)$, ce so A,B,P simetricne matirke.
7. $\text{tr}(ABP) = \text{tr}(A^T B^T P^T)$.

Za poljubna vektorja $x, y \in \mathbb{R}^n$ velja:

$$\text{tr}(xy^T) = \text{tr}(x^T y)$$

7.7 Ce ima matrika A lastno vrednost λ , ki ji pripada lastni vektor \vec{x} , potem ima matrika $A + cI$ lastno vrednost $\lambda + c$ z istim lastnim vektorjem \vec{x} (velja samo z enotskimi matrikami I).

7.8 Lastne vrednosti trikotne matrike so enake diagonalnim elementom.

7.9 Denimo, da ima matrika $A \in \mathbb{R}^{n \times n}$ n linearno neodvisnih lastnih vektorjev $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$. Ce jih zlozimo kot stolpce v matriko S

$$S = [\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n],$$

potem je $T = S^{-1}AS$ diagonalna matrika z lastnimi vrednostmi $\lambda_i, i = 1, \dots, n$ na diagonalni

$$S^{-1}AS = T = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}.$$

Pozor! Lastni vektorji v matriki S morajo biti v istem vrstnem redu kot lastne vrednosti v matriki T.

7.10 Ce je $A = STS^{-1}$, potem je $A^k = ST^k S^{-1}$ za vsak $k \in \mathbb{N}$.

7.12 Vse lastne vrednosti realne simetricne matrike so realne.

7.13 Lastni vektorji realne simetricne matrike, ki pripadajo razlicnim lastnim vrednostim, so med seboj pravokotni.

7.14 Schurov izrek Za vsako kvadratno matriko reda n , ki ima le realne lastne vrednosti, obstaja taka ortogonalna matrika Q, da je

$$Q^T A Q = T$$

zgornjetrikotna matrika, ki ima lastne vrednosti (lahko so kompleksne) matrike A na diagonalni.

7.15 Spektralni izrek Vsako simetricno matriko A lahko razcepimo v produkt $A = QTQ^T$, kjer je Q ortogonalna matrika lastnih vektorjev, T pa diagonalna z lastnimi vrednostmi matrike A na diagonalni.

7.16 Vsako realno simetricno matriko lahko zapisemo kot linearno kombinacijo matrik ranga 1

$$A = \lambda_1 \vec{q}_1 \vec{q}_1^T + \lambda_2 \vec{q}_2 \vec{q}_2^T + \dots + \lambda_n \vec{q}_n \vec{q}_n^T,$$

kjer so \vec{q}_i stolpci matrike Q (torej lastni vektorji matrike A).

7.17 Za simetricno nesusingularno matriko A je stevilo pozitivnih pivotov enako stevilu pozitivnih lastnih vrednosti.

7.18 Kvadratna matrika je pozitivno definirana, kadar so vse njene lastne vrednosti pozitivne.

7.19 Kvadratna matrika reda 2 je pozitivno definirana natanko tedaj, kadar sta pozitivni sled in determinanta matrike.

7.20 Simetricna matrika A reda n je pozitivno definirana natanko tedaj, ko je za vsak vektor $\vec{x} \neq \vec{0} \in \mathbb{R}^n$

$$\vec{x}^T A \vec{x} > 0$$

7.21 Ce sta matriki A in B pozitivno definitni, je pozitivno definitna tudi njuna vsota $A + B$.

7.22 Matrika A je pozitivno definitna, kadar so vse njene vodilne glavne poddeterminante pozitivne.

7.23 Ce so stolpci matrike R linearno neodvisni, je matrika $A = R^T R$ pozitivno definitna.

7.24 Za vsako simetricno pozitivno definitno matriko A obstaja zgornjetrikotna matrika R, da je $A = R^T R$.

7.25 Simetricna matrika reda n , ki ima eno od spodnjih lastnosti, ima tudi ostale stiri:

1. Vseh n pivotov je pozitivnih;
2. Vseh n vodilnih glavnih determinant je pozitivnih;
3. Vseh n lastnih vrednosti je pozitivnih;
4. Za vsak $\vec{x} \neq \vec{0}$ je $\vec{x}^T A \vec{x} > 0$;
5. $A = R^T R$ za neko matriko R z linearno neodvisnimi stolpci.

7.26 Vsako realno $m \times n$ matriko A lahko zapisemo kot produkt $A = UEV^T$, kjer je matrika U ortogonalna $m \times m$, E diagonalna $m \times n$ in V ortogonalna $n \times n$.

7.27 Ce je matrika A simetricna in so vsej njeni elementi realni, potem je njen rang enak stevilu nenicelnih lastnih vrednosti matrike A.

$$\text{rang}(A) = \text{stevilo } \lambda A$$

7.28 Diagonalizacija oz podobnost matrik. Matriki A in B sta podobni, ce imata obe iste lastne vrednosti. Diagonalno matriko sestavimo tako, da v njeno diagonalo vpisemo lastne vrednosti. Matriko P pa sestavimo iz njenih lastnih vektorjev; po stolpcih.

$$A = PDP^{-1} \text{ oz. } D = P^{-1}AP$$

7.29 Spektralni razcep Naj bodo vektorji $\vec{q}_1, \dots, \vec{q}_n$ ONB iz 1. vektorjev matrike A za l. vrednost $\lambda_1, \dots, \lambda_n$, potem lahko matriko A zapisemo kot:

$$A = \lambda_1 \vec{q}_1 \vec{q}_1^T + \dots + \lambda_n \vec{q}_n \vec{q}_n^T$$

7.30 Nekaj lastnosti simetricnih matrik

- Vse lastne vrednosti simetricne matrike so realne. Lastni vektorji realne simetricne matrike, ki pripadajo razlicnim lastnim vrednostim, so med seboj pravokotni.
- Vsako realno simetricno matriko A lahko zapisemo kot $A = QDQ^T$, kjer je Q ortogonalna matrika lastnih vektorjev, D pa diagonalna matrika, ki ima na diagonalni pripadajoce lastne vrednosti matrike A.

8 Napredna linearna algebra

8.1 Schurov izrek

(Schur): Naj bo $A \in \mathbb{R}^{n \times n}$ matrika z lastnimi vrednostmi $\lambda_1, \dots, \lambda_n$. Potem obstaja ortogonalna matrika $Q \in \mathbb{R}^{n \times n}$ in zgornje trikotna matrika Z, ki ima na diagonalni $\lambda_1, \dots, \lambda_n$, da velja

$$A = QZQ^{-1} = QZQ^T.$$

- **Posledica:** Vsaka matrika $A \in \mathbb{R}^{n \times n}$ je podobna zgornje trikotni matriki.
- **Posledica:** Vsaka simetricna matrika $A \in \mathbb{R}^{n \times n}$ je ortogonalno podobna diagonalni matriki.

- **Posledica:** Če ima matrika $A \in \mathbb{R}^{n \times n}$ lastne vrednosti enake $\lambda_1, \lambda_2, \dots, \lambda_n$, potem je

$$\text{tr}(A) = \lambda_1 + \lambda_2 + \dots + \lambda_n$$

in

$$\det(A) = \lambda_1 \lambda_2 \dots \lambda_n.$$

- **Posledica (Cayley-Hamilton):** Če je $\Delta_A(x) = \det(A - xI_n)$ karakteristični polinom matrike A , potem velja $\Delta_A(A) = 0$.

8.2 Frobeinusova norma

Za matriki $A \in \mathbb{R}^{m \times n}$ in $B \in \mathbb{R}^{m \times n}$ definiramo

$$\langle A, B \rangle = \text{tr}(A^T B).$$

Za produkt $\langle A, B \rangle : \mathbb{R}^{m \times n} \times \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ velja za vse matrike $A, B, C \in \mathbb{R}^{m \times n}$ in za vse $\alpha, \beta \in \mathbb{R}$,

1. $\langle A, B \rangle = \langle B, A \rangle$,
2. $\langle \alpha A + \beta B, C \rangle = \alpha \langle A, C \rangle + \beta \langle B, C \rangle$,
3. $\langle A, A \rangle \geq 0$,
4. $\langle A, A \rangle = 0$ natanko tedaj, ko je $A = 0$.

Zato $\langle A, B \rangle$ imenujemo skalarni produkt matrik A in B .

Za matrike $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{m \times k}$ in $C \in \mathbb{R}^{k \times n}$ velja

$$\langle A, BC \rangle = \langle B^T A, C \rangle = \langle AC^T, B \rangle.$$

Frobeniusova norma matrike $A = [a_{ij}] \in \mathbb{R}^{m \times n}$ je definirana kot

$$\|A\|_F = \|A\| = \sqrt{\langle A, A \rangle} = \sqrt{\text{tr}(A^T A)}.$$

Velja:

$$\|A\|_F^2 = \sum_{i=1}^n \sum_{j=1}^m a_{ij}^2 = \sum_{i=1}^{\min(m,n)} \sigma_i^2.$$

Posledica:

$$\|A\|_F = \sqrt{\sum_{i=1}^n \lambda_i^2}$$

(Eckart, Young). Naj bo $A = U \Sigma V^T$ razcep singularnih vrednosti matrike $A \in \mathbb{R}^{m \times n}$, $m \geq n$, kjer $U = [u^{(1)} \dots u^{(m)}]$ in $\mathbb{R}^{m \times m}$ in $V = [v^{(1)} \dots v^{(n)}]$ in $\mathbb{R}^{n \times n}$. Potem je matrika A_k iz $\mathbb{R}^{m \times n}$ ranga k , $k \leq n$, ki je med vsemi matrikami ranga k v Frobeniusovi normi najbližje matriki A , enaka

$$A_k = \sigma_1 u^{(1)} (v^{(1)})^T + \sigma_2 u^{(2)} (v^{(2)})^T + \dots + \sigma_k u^{(k)} (v^{(k)})^T$$

in velja

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_n^2}.$$

(Velja torej $\|A - A_k\|_F \leq \|A - X\|_F$ za $\|A - X\|_F$ za vse matrike $X \in \mathbb{R}^{m \times n}$, za katere velja $\text{rank}(X) = k$.)

8.3 Kroneckerjev produkt

Kroneckerjev produkt (tudi tenzorski produkt) matrik $A = [a_{ij}] \in \mathbb{R}^{m \times n}$ in $B \in \mathbb{R}^{p \times q}$ je $mp \times nq$ matrika

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{R}^{mp \times nq}.$$

Če so matrike A, B, C in D primerne velikosti, potem veljajo naslednje enakosti:

1. $0 \otimes A = A \otimes 0 = 0$
2. $\alpha \otimes A = A \otimes \alpha = \alpha A$ za vsak $\alpha \in \mathbb{R}$
3. $(\alpha A) \otimes B = A \otimes (\alpha B) = \alpha(A \otimes B)$
4. $(A + B) \otimes C = A \otimes C + B \otimes C$ in $A \otimes (B + C) = A \otimes B + A \otimes C$
5. $(A \otimes B)^T = A^T \otimes B^T$
6. $(A \otimes B) \otimes C = A \otimes (B \otimes C)$.
7. $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$.
8. $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$ če A in B obrnljivi.
9. $\text{tr}(A \otimes B) = \text{tr}(A)\text{tr}(B)$
10. $\text{rang}(A \otimes B) = \text{rang}(A)\text{rang}(B)$
11. Če ima matrika $A \in \mathbb{R}^{n \times n}$ lastne vrednosti $\lambda_1, \dots, \lambda_m$ in ima matrika B lastne vrednosti μ_1, \dots, μ_n , potem je množica lastnih vrednosti matrike $A \otimes B$ enaka:

$$S_\lambda = \{\lambda_i \mu_j; \lambda_i \text{ lastna vrednost } A, \mu_j \text{ lastna vrednost } B\}$$

$$\text{in } |S_\lambda| \leq mn$$

12. Če $A \in \mathbb{R}^{n \times n}$ in $B \in \mathbb{R}^{m \times m}$, potem je $\det(A \otimes B) = (\det A)^m (\det B)^n$.

Posledica:

$$\|A \otimes B\|_F = \|A\|_F \cdot \|B\|_F$$

8.4 Vektorizacija

Za matriko $A \in \mathbb{R}^{m \times n}$ označimo vektorizacijo matrike A kot

$$\text{vec}(A) = \begin{bmatrix} A^{(1)} \\ A^{(2)} \\ \vdots \\ A^{(n)} \end{bmatrix} \in \mathbb{R}^{mn}.$$

vec je preslikava iz $\mathbb{R}^{m \times n}$ v \mathbb{R}^{mn} .

Za matrike $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$ in $C \in \mathbb{R}^{p \times r}$ velja:

$$\text{vec}(ABC) = (C^T \otimes A) \text{vec}(B).$$

8.5 Definitnost matrik

Spomnimo se, da ima simetrična matrika $A \in \mathbb{R}^{n \times n}$ vse lastne vrednosti realne.

Simetrični matriki $A \in \mathbb{R}^{n \times n}$ pravimo

- **pozitivno semidefinitna**, če je $\mathbf{x}^T A \mathbf{x} \geq 0$ za vse $\mathbf{x} \in \mathbb{R}^n$.
- **pozitivno definitna**, če je $\mathbf{x}^T A \mathbf{x} > 0$ za vse neničelne $\mathbf{x} \in \mathbb{R}^n$.
- **negativno semidefinitna**, če je $\mathbf{x}^T A \mathbf{x} \leq 0$ za vse $\mathbf{x} \in \mathbb{R}^n$.
- **negativno definitna**, če je $\mathbf{x}^T A \mathbf{x} < 0$ za vse neničelne $\mathbf{x} \in \mathbb{R}^n$.
- **nedefinitna**, če je $\mathbf{x}^T A \mathbf{x} > 0$ za nekatere $\mathbf{x} \in \mathbb{R}^n$ in $\mathbf{y}^T A \mathbf{y} < 0$ za nekatere $\mathbf{y} \in \mathbb{R}^n$.

Posledica: Naj $A \in \mathbb{R}^{n \times n}$ simetrična z lastnimi vrednostmi $\lambda_1, \dots, \lambda_n$.

- A je **PSD** (pozitivno semidefinitna) $\Leftrightarrow \lambda_i \geq 0$ za $i = 1, \dots, n$.
- A je **PD** (pozitivno definitna) $\Leftrightarrow \lambda_i > 0$ za $i = 1, \dots, n$.
- A je **NSD** (negativno semidefinitna) $\Leftrightarrow \lambda_i \leq 0$ za $i = 1, \dots, n$.

- A je **ND** (negativno definitna) $\Leftrightarrow \lambda_i < 0$ za $i = 1, \dots, n$.

- A je **nedefinirana** \Leftrightarrow ima tako pozitivne kot negativne lastne vrednosti.

A je **PD** $\Leftrightarrow A$ je **PSD** in A obrnljiva.

(Sylvester). Simetrična matrika A je pozitivno definitna natanko tedaj, ko so determinante vseh vodilnih glavnih podmatrik matrike A pozitivne.

$$\det \begin{bmatrix} + & + & + & + \\ + & + & + & + \\ + & + & + & + \\ + & + & + & + \end{bmatrix} > 0 \quad \sim \text{PD}$$

Simetrična matrika A je negativno definitna natanko tedaj, ko je determinanta vsake $k \times k$ vodilne glavne podmatrike A pozitivna, če je k sodo število, ter negativna, če je k liho število.

$$\det \begin{bmatrix} - & + & - & + \\ + & - & + & - \\ - & + & - & + \\ + & - & + & - \end{bmatrix} \sim \text{ND}$$

Izrek: Naj $A \in \mathbb{R}^{n \times n}$ simetrična ranga r . Velja

- A je PSD \Leftrightarrow obstaja $B \in \mathbb{R}^{n \times r}$, da je $A = BB^T$.
- A je PD \Leftrightarrow obstaja $B \in \mathbb{R}^{n \times n}$, da je $A = BB^T$.
- A je NSD \Leftrightarrow obstaja $B \in \mathbb{R}^{n \times r}$, da je $A = -BB^T$.
- A je ND \Leftrightarrow obstaja $B \in \mathbb{R}^{n \times n}$, da je $A = -BB^T$.
- A je nedefinirana \Leftrightarrow obstaja tako pozitivne kot negativne lastne vrednosti.

A je PD $\Leftrightarrow A$ je PSD in A obrnljiva.

(Razcep Choleskega). Obrnljiva matrika $A \in \mathbb{R}^{n \times n}$ ima razcep Choleskega

$$A = LL^T,$$

kjer je $L \in \mathbb{R}^{n \times n}$ spodnje trikotna matrika, natanko tedaj, ko je A simetrična in pozitivno definitna.

Z uporabo spodnjega (rekurzivnega) algoritma: Simetrično matriko $A \in \mathbb{R}^{n \times n}$ zapišemo v bločni obliki

$$A_1 := A = \begin{bmatrix} a_{11} & b^T \\ b & B \end{bmatrix}$$

in definiramo

$$L_1 := \begin{bmatrix} \sqrt{a_{11}} & 0^T \\ \frac{1}{\sqrt{a_{11}}}b & I_{n-1} \end{bmatrix}.$$

Tedaj je

$$A_1 = \begin{bmatrix} a_{11} & b^T \\ b & B \end{bmatrix} = L_1 \begin{bmatrix} 1 & 0^T \\ 0 & B - \frac{1}{a_{11}}bb^T \end{bmatrix} L_1^T.$$

Ponovimo na simetrični matriki $A_2 := B - \frac{1}{a_{11}}bb^T \in \mathbb{R}^{(n-1) \times (n-1)}$.

Naj bodo L_2, L_3, \dots, L_n matrike, ki jih dobimo v ponovljenih korakih. Matrika L je potem

$$L = L_1 \cdot \begin{bmatrix} 1 & 0^T \\ 0 & L_2 \end{bmatrix} \cdot \begin{bmatrix} I_2 & 0 \\ 0 & L_3 \end{bmatrix} \cdots \begin{bmatrix} I_{n-1} & 0 \\ 0 & L_n \end{bmatrix}$$

8.6 Vektorski prostori

Realni vektorski prostor V je množica **vektorjev** v , za katere imamo definirani dve notranji operaciji

- seštevanje vektorjev ($u, v \in V \Rightarrow u + v \in V$),
- množenje vektorjev z realnimi števili ($v \in V, \alpha \in \mathbb{R} \Rightarrow \alpha v = \alpha \cdot v \in V$),

z lastnostmi

1. $u + v = v + u$ in $(u + v) + w = u + (v + w)$,
2. obstaja ničelni vektor 0 in velja $v + 0 = 0 + v = v$,
3. za vsak $v \in V$ obstaja nasprotni vektor $-v$, za katerega velja $v + (-v) = (-v) + v = 0$,
4. $1 \cdot v = v$ za vsak $v \in V$,
5. $(\alpha\beta) \cdot v = \alpha \cdot (\beta \cdot v)$,
6. $(\alpha + \beta) \cdot v = \alpha \cdot v + \beta \cdot v$,
7. $\alpha \cdot (u + v) = \alpha \cdot u + \alpha \cdot v$,

za poljubne $u, v, w \in V$ in $\alpha, \beta \in \mathbb{R}$.

Izrek: Naj bo V vektorski prostor. Potem velja

1. V vsebuje ničelni vektor 0 ,
2. v vsakem vektorskem prostoru V je ničelni vektor 0 en sam,
3. $\alpha \cdot 0 = 0$ za vsak $\alpha \in \mathbb{R}$,
4. $0 \cdot v = 0$ za vsak $v \in V$.

Za vektorje $v_1, v_2, \dots, v_n \in V$ in skalare $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$ imenujemo vektor

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n$$

linearna kombinacija vektorjev v_1, v_2, \dots, v_n . Denimo, ničelni vektor 0 je

$$0 \cdot v_1 + 0 \cdot v_2 + \dots + 0 \cdot v_n$$

je linearna kombinacija poljubnih vektorjev $v_1, v_2, \dots, v_n \in V$. Linearno kombinacijo z izključno ničelnimi koeficienti imenujemo **trivialna linearna kombinacija**.

Če je podmnožica U vektorskega prostora V

- (1) zaprta za seštevanje ($u, v \in U \Rightarrow u + v \in U$) in
- (2) zaprta za množenje vektorjev z realnimi števili ($v \in U, \alpha \in \mathbb{R} \Rightarrow \alpha v \in U$),

potem jo imenujemo **vektorski podprostor** prostora V .

Izrek: Podmnožica U vektorskega prostora V je vektorski podprostor natanko tedaj, ko je poljubna linearna kombinacija $\alpha u + \beta v$ vektorjev $u, v \in U$ tudi vsebovana v U .

Vsak vektorski podprostor po (2) vsebuje tudi vektor $0 \cdot v = 0$. Zatorej podmnožica vektorskega prostora, ki ne vsebuje ničelnega vektorja, ne more biti vektorski podprostor.

Ker lastnosti (1)-(7) veljajo za poljubne elemente vektorskega prostora V , veljajo tudi za vse elemente vektorskega podprostora U v V . Poleg tega je vektorski podprostor po definiciji zaprt za seštevanje in množenje s števili. Zatorej je vsak vektorski podprostor hkrati tudi vektorski prostor.

8.6.1 Linearna ogrinjača

$\mathcal{L}\{v_1, v_2, \dots, v_n\}$ vektorjev v_1, v_2, \dots, v_n je množica vseh linearnih kombinacij vektorjev v_1, v_2, \dots, v_n .

Ker je linearna kombinacija linearnih kombinacij vektorjev $v_1, v_2, \dots, v_n \in V$ zopet linearna kombinacija vektorjev v_1, v_2, \dots, v_n , je po Izreku 2 linearna ogrinjača $\mathcal{L}\{v_1, v_2, \dots, v_n\}$ linearni podprostor v V . Pravimo, da vektorji v_1, v_2, \dots, v_n **napenjajo prostor** $\mathcal{L}\{v_1, v_2, \dots, v_n\}$.

Ne le, da je linearna ogrinjača vektorski prostor. Velja celo več.

Linearna ogrinjača vektorjev v_1, v_2, \dots, v_n , vektorskega prostora V je najmanjši vektorski podprostor v V , ki vsebuje vektorje v_1, v_2, \dots, v_n .

8.6.2 Baza vektorskega prostora

Vektorji v_1, v_2, \dots, v_n v V so **linearno odvisni**, če obstaja vektor v_k , ki je linearna kombinacija ostalih $v_1, v_2, \dots, v_{k-1}, v_{k+1}, \dots, v_n$:

$$v_k = \alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_{k-1} v_{k-1} + \alpha_{k+1} v_{k+1} + \dots + \alpha_n v_n,$$

kjer $\alpha_i \in \mathbb{R}$.

Vektorji v_1, v_2, \dots, v_n v V so **linearno neodvisni**, če niso linearno odvisni. Ekvivalentno, v_1, v_2, \dots, v_n v V so linearno neodvisni, če je njihova trivialna linearna kombinacija edina njihova linearna kombinacija, ki je enaka ničelnemu vektorju 0. Z drugimi besedami, v_1, v_2, \dots, v_n v V so linearno neodvisni, če iz

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n = 0$$

sledi

$$\alpha_1 = \alpha_2 = \dots = \alpha_n = 0.$$

Množica vektorjev $\{v_1, v_2, \dots, v_n\}$ je **baza** vektorskega prostora V , če

(B1) so v_1, v_2, \dots, v_n linearno neodvisni in

(B2) v_1, v_2, \dots, v_n napenjajo prostor V .

Izrek: Vsak vektorski prostor ima neštevno baz. Vse baze vektorskega prostora imajo enako število vektorjev.

Dimenzija prostora V je enaka moči (poljubne) baze prostora V . Označimo jo z $\dim V$.

Izrek: Za vsako bazo vektorskega prostora V je zapis poljubnega vektorja $v \in V$ kot linearna kombinacija baznih vektorjev vedno enoličen.

8.6.3 Linearne preslikave

Naj bosta V in U vektorska prostora. Preslikava $\tau : V \rightarrow U$ je **linearna preslikava**, če velja

$$(1) \quad \tau(v + u) = \tau(v) + \tau(u) \text{ za vsaka } v, u \in V \text{ in}$$

$$(2) \quad \tau(\alpha v) = \alpha \tau(v) \text{ za vsak } v \in V \text{ in vsak } \alpha \in \mathbb{R}.$$

Preslikava $\tau : V \rightarrow U$ je linearna natanko tedaj, ko velja

$$\tau(\alpha v + \beta u) = \alpha \tau(v) + \beta \tau(u)$$

za vse $v, u \in V$ ter vse $\alpha, \beta \in \mathbb{R}$.

Za poljubno linearno preslikavo $\tau : V \rightarrow U$ velja $\tau(0_V) = 0_U$.

Naj bodo $\tau, \psi : V \rightarrow U$ ter $\theta : U \rightarrow W$ linearne preslikave in naj bo $\gamma \in \mathbb{R}$.

$$(1) \quad \mathbf{Vsota} \quad \tau + \psi : V \rightarrow U \text{ je preslikava, definirana s predpisom}$$

$$(\tau + \psi)(v) = \tau(v) + \psi(v).$$

$$(2) \quad \mathbf{Produkt s skalarjem} \quad \gamma \tau : V \rightarrow U \text{ je preslikava, definirana s predpisom}$$

$$(\gamma \tau)(v) = \gamma \tau(v).$$

$$(3) \quad \mathbf{Kompozitum} \quad \theta \circ \tau : V \rightarrow W \text{ je preslikava, definirana s predpisom}$$

$$(\theta \circ \tau)(v) = \theta(\tau(v)).$$

Izrek: Vsota, produkt s skalarjem in kompozitum linearnih preslikav so linearne preslikave.

Posledica: Množica vseh linearnih preslikav iz vektorskega prostora V v vektorski prostor U je vektorski prostor

Izrek: Naj bodo $\tau, \psi : V \rightarrow U$ ter $\theta : U \rightarrow W$ linearne preslikave in naj bo $\alpha \in \mathbb{R}$.

1. Matrika, ki ustreza vsoti preslikav $\tau + \psi$, je enaka vsoti matrik posameznih preslikav.

$$A_{\tau+\psi, B}^C = A_{\tau, B}^C + A_{\psi, B}^C$$

2. Matrika, ki ustreza produktu s skalarjem $\alpha \tau$, je enaka večkratniku matrike preslikave.

$$A_{\alpha \tau, B}^C = \alpha A_{\tau, B}^C$$

3. Matrika, ki ustreza kompozitumu preslikav, je enaka produktu matrik posameznih preslikav.

$$A_{\theta \circ \tau, B}^D = A_{\theta, C}^D \cdot A_{\tau, B}^C$$

4. Matrika, ki ustreza inverzu obrnljive preslikave, je enaka inverzu matrike te preslikave. Torej, če je τ obrnljiva preslikava, je obrnljiva tudi matrika $A_{\tau, B}^C$. Velja

$$A_{\tau^{-1}, C}^B = (A_{\tau, B}^C)^{-1}$$

Neničelnemu vektorju v v V pravimo *lastni vektor* linearne preslikave $\tau : V \rightarrow V$, če velja

$$\tau(v) = \lambda v.$$

Številu λ pravimo *lastna vrednost* linearne preslikave τ .

Izrek: Vsaka lastna vrednost linearne preslikave τ je tudi lastna vrednost poljubne matrike A_τ , ki pripada preslikavi τ . Vse matrike, ki pripadajo dani linearni preslikavi τ imajo enake lastne vrednosti.

Pravimo, da je linearno preslikavo $\tau : V \rightarrow V$ mogoče *diagonalizirati*, če obstaja baza, v kateri pripada preslikavi diagonalna matrika.

Izrek: Linearno preslikavo $\tau : V \rightarrow V$ je mogoče diagonalizirati natanko tedaj, ko obstaja baza prostora V sestavljena iz lastnih vektorjev preslikave τ .

Naj bo $\tau : V \rightarrow U$ linearna preslikava vektorskega prostora V v vektorski prostor U .

Def: Jedro linearne preslikave τ je množica $\ker(\tau)$ vseh vektorjev $v \in V$, za katere velja

$$\tau(v) = 0.$$

Def: Slika linearne preslikave je množica $\text{im}(\tau) = \{\tau(v) : v \in V\} \subseteq U$.

Izrek: Jedro $\ker \tau$ linearne preslikave $\tau : V \rightarrow U$ je vektorski podprostor v V , slika $\text{im} \tau$ pa vektorski podprostor v U .

Izrek: Naj bo $\tau : V \rightarrow U$ linearna preslikava iz vektorskega prostora V v vektorski prostor U .

1. τ je injektivna natanko tedaj, ko je $\ker \tau = \{0\}$.

2. τ je surjektivna natanko tedaj, ko je $\text{im} \tau = U$.

Izrek: Naj bo $\tau : V \rightarrow U$ linearna preslikava in naj bo $A = A_{\tau, B, C}$ matrika, ki pripada preslikavi τ . Potem je

1. $\dim(\text{im}(\tau)) = \text{rank}(A)$,
2. $\dim(\ker(\tau)) + \dim(\text{im}(\tau)) = \dim(V)$.

Posledica: Naj bo $\tau : V \rightarrow U$ linearna preslikava, $\dim V = \dim U = n$ in naj bo A neka matrika, ki pripada τ . Naslednje trditve so ekvivalentne:

1. τ je bijektivna.
2. τ je injektivna.
3. τ je surjektivna.
4. A je obrnljiva.
5. $\ker \tau = \{0\}$.
6. $N(A) = \{0\}$.
7. $\text{im} \tau = U$.

8. $C(A) = \mathbb{R}^n$.

9. Rang matrike A je n .

10. Vrstice matrike A so linearno neodvisne.

11. Vrstice matrike A razpenjajo \mathbb{R}^n .

12. Vrstice matrike A tvorijo bazo \mathbb{R}^n .

13. Stolpci matrike A so linearno neodvisni.

14. Stolpci matrike A razpenjajo \mathbb{R}^n .

15. Stolpci matrike A tvorijo bazo \mathbb{R}^n .

16. $\det A \neq 0$.

17. Homogeni sistem enačb $Ax = 0$ ima le trivialno rešitev.

18. Sistem enačb $Ax = b$ ima rešitev za vsak $b \in \mathbb{R}^n$.